




# 没有免费午餐定理 (No Free Lunch Theorem)

如果我们不对特征空间有先验假设，则所有算法的平均表现是一样的！



0: Class 1  
X: Class 2



0 花瓣  
X 蜜蜂


特征差距小的样本更有可能是一类~

## 支持向量机 (Support Vector Machine)

小样本方法


小样本依旧能获得很好的结果!!!

### ① 线性模型




线性可分 (Linear Separable)

performance measure  
性能指标



非线性可分 (None Linear Separable)



d: Margin

支持向量 (Support Vectors)  
"→" 所指的数据

定义:

- ① 训练数据及标签  $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$   
 $x$  向量  $\rightarrow$  标签  $(y = +1/-1)$
- ② 线性模型  $(W, b)$   $W^T x + b = 0$  (超平面)  
 $(Hyperplane)$   
 $X = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$   $w = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix}$   
 $w$  向量  $\rightarrow$  系数 常数

③ 一个训练集线性可分是指:

- $\{ (x_i, y_i) \}_{i=1 \sim N}$
- $\exists (w, b)$ , 使: 对  $\forall i=1 \sim N$ , 有:
- (a) 若  $y_i = +1$ , 则  $w^T x_i + b \geq 0$
- (b) 若  $y_i = -1$ , 则  $w^T x_i + b < 0$



$y_i [w^T x_i + b] \geq 0$  ---- 公式1

## 优化问题: (凸优化问题, 二次规划问题)

- 最小化 (Minimize):  $\|w\|^2 \cdot \frac{1}{2}$  求导方便
- 限制条件 (Subject to):  $y_i (w^T x_i + b) \geq 1, i=1 \sim N$

事实1:  $w^T x + b = 0$  与  $aw^T x + ab = 0$  是同一个平面  
 $a \in \mathbb{R}^+$   
 若  $(w, b)$  满足公式1, 则  $(aw, ab)$  也满足公式1

事实2: 点到面的距离公式:  
 平面:  $w_1 x + w_2 y + b = 0$ , 点:  $(x_0, y_0)$  到平面的距离  
 $d = \frac{|w_1 x_0 + w_2 y_0 + b|}{\sqrt{w_1^2 + w_2^2}}$


向量  $x_0$  到超平面  $w^T x + b = 0$  的距离  
 $d = \frac{|w^T x_0 + b|}{\|w\|}$   $\rightarrow \sqrt{w_1^2 + w_2^2 + \dots + w_n^2}$

我们可以用  $a$  来缩放  
 $(w, b) \rightarrow (aw, ab)$   
 最终使在支持向量  $x_0$  上有:  
 $|w^T x_0 + b| = 1$   
 此时支持向量与平面距离:  
 $d = 1/\|w\|$


## 二次规划 (Quadratic Programming):

- ① 目标函数 (Objective Function) 是二次项
- ② 限制条件是一次项

要么无解/要么只有一个取值



$\Rightarrow$  全局最优解



$\Rightarrow$  Hard to solve

① SVM 是最大化间隔 (Margin) 的分类算法

② 优化问题


训练样本  $\{ (x_i, y_i) \}_{i=1 \sim N}$   
 $x$  向量  $\rightarrow$  标签

- ③ 最小化:  $\frac{1}{2} \|w\|^2$
- 限制条件:  $y_i [w^T x_i + b] \geq 1 (i=1 \sim N)$

SVM 处理非线性:


- ① 最小化:  $\frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i$  (Soft Variable) 松弛变量
- ② 限制条件:  $y_i [w^T x_i + b] \geq 1 - \xi_i (i=1 \sim N)$   
 $\xi_i \geq 0$

$C \sum_{i=1}^N \xi_i$ : 正则项 (Regulation Term)  
 $\rightarrow$  事先规定的参数



定义一个高维的映射  $\phi(x)$ :

$x$  (低维)  $\xrightarrow{\phi}$   $\phi(x)$  (高维)



$\Rightarrow$  异或问题

$x_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \in C, x_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \in C, x_3 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \in C, x_4 = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \in C$

$\phi(x): x = \begin{bmatrix} a \\ b \end{bmatrix} \xrightarrow{\phi} \phi(x) = \begin{bmatrix} a^2 \\ b^2 \\ ab \end{bmatrix}$

$\phi(x_1) = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \quad \phi(x_2) = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \in C$

$\phi(x_3) = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \quad \phi(x_4) = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \in C$

我们可以不知道无限维映射  $\phi(x)$  的显式表达,  
 只需要知道一个核函数 (Kernel function)

$k(x_1, x_2) = \phi(x_1)^T \phi(x_2)$

则①这个优化式依然可解

核函数

①  $k(x_1, x_2) = e^{-\frac{\|x_1 - x_2\|^2}{2\sigma^2}}$  (高斯核)  
 $= \phi(x_1)^T \phi(x_2)$

②  $k(x_1, x_2) = (x_1^T x_2 + 1)^d$  (多项式核)  
 $= \phi(x_1)^T \phi(x_2)$

$k(x_1, x_2) \Rightarrow \phi(x_1)^T \phi(x_2)$  的必要条件:

①  $k(x_1, x_1) = k(x_2, x_2)$  (对称性)

②  $\forall C_i, x_i (i=1 \sim N)$ , 有: (半正定性)  
 $\sum_{i=1}^N \sum_{j=1}^N C_i C_j k(x_i, x_j) \geq 0$

## 优化理论:

- ① « Convex optimization »
- ② « Nonlinear Programming »

原问题 (Primal Problem) → 非常奇怪

最小化:  $f(w)$

限制条件:  $g_i(w) \leq 0 \quad (i=1 \sim K)$   
 $A_i(w) = 0 \quad (i=1 \sim M)$

对偶问题 (Dual Problem):

① 定义:  $L(w, \alpha, \beta)$

$$= f(w) + \sum_{i=1}^K \alpha_i g_i(w) + \sum_{i=1}^M \beta_i A_i(w)$$

$$= f(w) + \alpha^T g(w) + \beta^T A(w)$$

$$\begin{bmatrix} g_1(w) \\ g_2(w) \\ \vdots \\ g_K(w) \end{bmatrix} \quad \begin{bmatrix} A_1(w) \\ A_2(w) \\ \vdots \\ A_M(w) \end{bmatrix}$$

② 对偶问题的定义:

最大化:  $\theta(\alpha, \beta) = \inf_{w \in \mathbb{R}^n} L(w, \alpha, \beta)$  → 最小值

限制条件:  $\alpha_i \geq 0 \quad (i=1 \sim K)$

定理: 如果  $w^*$  是原问题的解, 而  $\alpha^*, \beta^*$  是对偶问题的解, 则有:

$$f(w^*) \geq \theta(\alpha^*, \beta^*)$$

$$\text{证: } \theta(\alpha^*, \beta^*) = \inf_{w \in \mathbb{R}^n} L(w, \alpha^*, \beta^*) \leq L(w^*, \alpha^*, \beta^*)$$

$$= f(w^*) + \sum_{i=1}^K \alpha_i^* g_i(w^*) + \sum_{i=1}^M \beta_i^* A_i(w^*) \leq f(w^*)$$

$$\text{定义: } G = f(w^*) - \theta(\alpha^*, \beta^*) \geq 0$$

$G$  叫做原问题与对偶问题的问距 (Duality Gap)

对于某些特定优化问题, 可以证明:  $G = 0$

强对偶定理:

若  $f(w)$  为凸函数, 且  $g(w) = Aw + b$ ,  $A_i(w) = Cw + b$ ,

则此优化问题的原问题与对偶问题问距为 0, 即  $f(w^*) = \theta(\alpha^*, \beta^*)$

对于  $\forall i=1 \sim K$ , 或者  $\alpha_i^* = 0$ , 或者  $g_i(w^*) = 0$   
(KKT 条件)

将支持向量机的原问题转化为对偶问题


最小化  $\frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$

限制条件  $y_i [w^T \phi(x_i) + b] \geq 1 - \xi_i$   
 $\xi_i \geq 0$

$$\frac{1}{2} \|w\|^2 - C \sum_{i=1}^n \xi_i$$

$$\begin{aligned} & w y_i [w^T \phi(x_i) + b] \leq 1 + \xi_i \\ & \xi_i \leq 0 \end{aligned}$$

关于凸函数:



$\forall w_1, w_2, \forall \lambda \in [0, 1]$ ,

$$f(\lambda w_1 + (1-\lambda) w_2) \leq \lambda f(w_1) + (1-\lambda) f(w_2)$$

数学定义

对偶问题:

最大化  $\theta(\alpha, \beta) = \inf_{w \in \mathbb{R}^n} \left\{ \frac{1}{2} \|w\|^2 - C \sum_{i=1}^n \xi_i + \sum_{i=1}^n \alpha_i [1 - \xi_i - y_i w^T \phi(x_i) - y_i b] \right\}$

限制条件  $\alpha_i \geq 0, \beta_i \geq 0 \quad (i=1 \sim N)$

$$\begin{cases} \frac{\partial L}{\partial w} = 0 \Rightarrow w - \sum_{i=1}^n \alpha_i y_i \phi(x_i) = 0 \\ \frac{\partial L}{\partial \xi_i} = 0 \Rightarrow -C + \beta_i + \alpha_i = 0 \\ \frac{\partial L}{\partial b} = 0 \Rightarrow -\sum_{i=1}^n \alpha_i y_i = 0 \end{cases}$$

$$w = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix} \quad f(w) \rightarrow \text{数}$$

若  $f(w) = \frac{1}{2} \|w\|^2$

则  $\frac{\partial f}{\partial w} = w$

若  $f(w) = w^T x$

则  $\frac{\partial f}{\partial w} = x$

最大化:  $\theta(\alpha, \beta) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j K(x_i, x_j)$

限制条件:  $0 \leq \alpha_i \leq C$   
 $\sum_{i=1}^n \alpha_i y_i = 0$

凸优化问题

SMO 算法

测试流程:

测试样本  $x$ ,

$\begin{cases} \text{若 } w^T \phi(x) + b \geq 0, \text{ 则 } y = +1 \\ \text{若 } w^T \phi(x) + b < 0, \text{ 则 } y = -1 \end{cases}$

SVM 算法:

① 训练流程

输入训练样本  $\{(x_i, y_i)\}_{i=1 \sim n}$

(解优化问题)

最大化:  $\theta(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j K(x_i, x_j)$

限制条件:  $0 \leq \alpha_i \leq C$

$$\sum_{i=1}^n \alpha_i y_i = 0$$

算  $b$ , 找一个  $0 < \alpha_i < C$ .

$$b = \frac{1 - y_i \sum_{j=1}^n \alpha_j y_j K(x_i, x_j)}{y_i}$$

② 测试流程

输入测试样本  $x$

$\begin{cases} \text{若 } \sum_{i=1}^n \alpha_i y_i K(x_i, x) + b \geq 0, \text{ 则 } y = +1 \\ \text{若 } \sum_{i=1}^n \alpha_i y_i K(x_i, x) + b < 0, \text{ 则 } y = -1 \end{cases}$

SVM 内核函数:

Linear (线性内核):  $K(x, y) = x^T y$

Poly (多项式内核):  $K(x, y) = (x^T y + 1)^d$

Rbf (高斯径向基函数内核):  $K(x, y) = e^{-\frac{\|x-y\|^2}{2\sigma^2}}$

Tanh (Tanh 核):  $K(x, y) = \tanh(\beta x^T y + b)$      $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$